

Roteiro prático 04

Origem das proteínas e anotação das árvores filogenéticas

Prof. Dr. Tetsu Sakamoto

Introdução

*“Se eu souber os genes do teu corpo
que os outros bichos também têm,
sei qual é mais novo, mais antigo,
vou te conhecer como ninguém.”*

(Melô do LCA, por J. Miguel Ortega)

Saber a origem de uma proteína ou de uma família proteica faz parte dos objetivos de vários trabalhos científicos. Através dela, podemos ter uma noção de quando um processo biológico que ela desempenha surgiu e consequentemente a sua abrangência em outros organismos. **Mas como saber quando uma proteína foi originada?** Uma das formas de acessar esta questão é verificando a abrangência dessa proteína entre os organismos vivos. Então podemos supor que a proteína tenha surgido no **último ancestral comum** (*lowest common ancestor* - LCA) dos organismos que possuem a proteína de interesse. Para isso realizamos análise de **grupos de ortólogos**. Grupos de ortólogos é um grupo de sequências de proteínas originadas de um mesmo ancestral.

Objetivos

No presente roteiro, realizaremos de forma prática como podemos determinar a origem de uma proteína. Será também demonstrado como podemos realizar anotações nas árvores filogenéticas.

Materiais

Os materiais necessários para a realização deste roteiro incluem:

- Computador pessoal com acesso a internet;
- Navegador de internet;
- TaxOnTree (<http://bioinfo.icb.ufmg.br/taxontree/>).

Origem da proteína tetherina

Vamos supor que eu queira saber a origem da proteína [tetherina](#), uma proteína conhecida por evitar a proliferação do vírus no organismo. Para verificar a sua origem, podemos consultar um banco de dados de grupos de ortólogos e encontrar os organismos que possuem esta proteína. Na web você pode encontrar vários bancos de dados de grupos de ortólogos:

- OMA (<https://omabrowser.org>)
- eggNOG (<http://eggnog5.embl.de>)
- OrthoDB (<https://www.orthodb.org>)
- InParanoid (<https://inparanoid.sbc.su.se>)

Vamos entrar no banco do eggNOG, por exemplo, e procurar pelo [grupo de ortólogo contendo essa proteína](#).

Posteriormente, podemos baixar a lista de organismos que possuem uma sequência nesse grupo de ortólogos e verificar o LCA desses organismos. Para isso, podemos nos aproveitar da classificação taxonômica do [NCBI Taxonomy](#), que te fornece uma árvore taxonômica contendo todos os organismos que possuem alguma sequência depositada em seu banco de dados.



Se o LCA desses organismos estiver mais próximo da raiz, significa que esta proteína tem uma origem mais antiga, e provavelmente abrangente entre os organismos. Quanto mais próximo da folha está o LCA, mais recente foi o surgimento deste gene e, portanto, mais específico para um determinado grupo de organismo.

É possível acessar o LCA utilizando a ferramenta [Taxallnomy](#) ou a ferramenta [Genesis](#), ambas ferramentas produzidas no Laboratório de Biodados (UFMG). No eggNOG, baixe a tabela contendo as informações dos acessos que fazem parte do grupo de ortólogo.

EggNOG 5.0.0

Search protein or OG

Found 1 matches in 0.07 seconds (1KB)

Navigation

- Home
- Sequence search
- eggNOG-mapper v2 (Batch Functional Annotation)
- Downloads
- API
- Methods

Query gene/protein: Q10589 in *Any species* and Query OG: ENOG502TB0V

Add target taxa...

ENOG502TB0V

Eukaryota

Function unknown

negative regulation of plasmacytoid dendritic cell cytokine production

70 proteins 57 species

Ortholog

Organism

★ 1 matches

BST2 *Homo sapiens*

BST2 *Cricetulus griseus*

XP_005087886.1 *Mesocricetus auratus*

XP_006995988.1 *Peromyscus maniculatus*

BST2 *Mus musculus*

BST2 *Rattus norvegicus*

BST2 *Octodon degus*

BST2 *Heterocephalus glaber*


62 more...

Fine-grained Orthologs Orthologous Group Taxonomic Profile Functional Profile Alignment Phylogenetic Tree Download

Showing ALL group members Download list Download sequences


Organism	Members	Close homologs in this group (preferred gene names)
<i>Cricetulus griseus</i>	10029.NP_001231044.1	Bst2
<i>Mesocricetus auratus</i>	10036.XP_005087886.1	10036.XP_005087886.1
<i>Peromyscus maniculatus</i>	10042.XP_006995988.1	10042.XP_006995988.1
<i>Mus musculus</i>	10090.ENSMUSP00000051921	Bst2

Nesta tabela, vocês vão encontrar uma coluna contendo os taxIDs de cada acesso. Copie elas e submeta às ferramentas. Neste caso, vocês vão reparar que o LCA dos organismos neste grupo de ortólogos é Eutheria, um grupo de mamíferos que abrangem todos os placentários.




Árvore taxonômica contendo as linhagens de organismos que possuem o gene BST2 (Tetherin). Obtido em: <http://bioinfo.icb.ufmg.br/taxallnomy/>

Se você realizar esta análise em todos os grupos de ortólogos que um organismo contém uma proteína, podemos ter uma noção da quantidade de genes que foram surgindo ao longo de uma linhagem taxonômica ou do tempo. A esta análise denominamos de **filoestratigrafia**.



Contagem de genes originados ao longo da linhagem de humanos. Fonte: <http://maxixe.icb.ufmg.br:8080/Genesis/species/speciesOrigin>



Contagem acumulada de genes de humanos surgindo ao longo do tempo. A escala de tempo foi obtida pelo [TimeTree](#). Fonte: Lopes et al., 2016.

No entanto, alguns grupos de ortólogos possuem uma história evolutiva mais complexa contendo duplicações e deleções. Para obter mais detalhamento sobre esses eventos evolutivos, uma análise filogenética se faz necessária.

Evolução de SLCO1B1 e a origem das duplicações e deleções


O SLCO1B1 (solute carrier organic anion transporter family member 1B1) é uma proteína encontrada nas células do fígado. Ele transporta compostos do sangue para o fígado para que eles possam realizar a sua limpeza. O SLCO1B1, por exemplo, transporta a bilirrubina, que é uma substância amarelada produzida quando as hemácias são degradadas. No fígado, a bilirrubina é dissolvida pela bile e é excretada do corpo. O SLCO1B1 faz parte de uma grande família de transportadores que possuem vários membros. Vamos realizar uma análise preliminar desta proteína utilizando o TaxOnTree.

Para isso:

1. Vá ao site do [TaxOnTree](https://taxon.tree);
2. Selecione “query identifier”;
3. Coloque na caixa de texto o número de acesso do UniProt da SLCO1B1 ([Q9Y6L6](https://www.uniprot.org/entry/Q9Y6L6));
4. Em “Blast Options”, selecione o banco UniProt Reference Proteomes, e configure o threshold para 30 e o e-value para 1e-10;
5. Clique em Submit;
6. Anote o número de job;
7. Em “Get your result”, coloque o número do job e selecione “Tree in Nexus”;
8. Caso o job tenha finalizado sem erro, a página irá baixar um arquivo no formato Nexus. Abra este arquivo no FigTree.

Obs.: Este procedimento já foi anteriormente realizado e sua árvore pode ser acessada pelo job de número 1122.

Ao abrir a árvore no TaxOnTree, vocês encontrarão a árvore formatada como abaixo:




Algumas configurações de visualização que podem ser feitas com as árvores anotadas com o TaxOnTree:

- Colorir os ramos de acordo com o LCA;

- Colorir os ramos de acordo com um nível taxonômico (Filo, classe, ordem, etc);
- Analisar o suporte dos ramos na árvore;
- Acrescentar a legenda de cores de acordo com a cor utilizada nos ramos;
- Mudar o tip label para um nível taxonômico ou LCA;
- Colorir o tip label de acordo com um nível taxonômico ou LCA;
- Acrescentar tip shape e colorir de acordo com um nível taxonômico ou LCA;

Evidenciando os nós internos que representam duplicações gênicas



Exercício

Segundo a árvore inferida, responda às seguintes perguntas:
Quanto eventos de duplicações podem ser observados no grupo dos Primatas?


A duplicação que deu origem ao SLCO1B1 deve ter ocorrido em qual ancestral?

É possível verificar deleções deste gene em algum grupo ou taxon? Se sim, em qual?

Analizando árvores grandes

Muitas vezes deparamos com árvores com centenas de amostras. Analisar árvores assim é desafiador, por isso, quanto mais você consegue incorporar informações aproveitando dos aspectos visuais da árvore, mais fácil será a sua análise e interpretação. O TaxOnTree pode te auxiliar nesse sentido.

Veja o conteúdo da árvore presente neste [link](#) no FigTree.



Tente submeter esta árvore no TaxOnTree. Para isso:

1. Utilize a query como: Q9NZM6/273-497
2. Configure o delimitador como "/" e a posição como 0 para que o TaxOnTree encontre corretamente os acessos UniProt.

Obs.: Este procedimento já foi realizado e pode ser obtido consultando o job 1124.

Exercício

Segundo a árvore inferida, responda às seguintes perguntas:


Quando ocorreu a duplicação entre o PKD2 e o PKD2L2 humano?

Quantos reinos (kingdoms) estão presentes nesta árvore?

Submetendo árvores sem acessos do NCBI/UniProt no TaxOnTree

Lembra da [árvore](#) que você inferiu usando a abordagem da supermatriz? Mesmo esta árvore, que não possui os acessos do NCBI ou UniProt podem ser submetidos ao TaxOnTree. Para isso, é necessário você fornecer-lhe uma tabela que informe o TaxID de cada amostra na árvore como deste [link](#).

Para auxiliar na construção dessa tabela, o TaxOnTree imprime as folhas que estão presentes na árvore.



Acrescentando outras anotações na árvore com o TaxOnTree

Este recurso só está disponível na versão local do TaxOnTree que só está disponível para o sistema Unix.


Baixe os seguintes arquivos:

- https://github.com/tetsufmbio/workshop/blob/master/data/crispr_cas1b.tree
- https://github.com/tetsufmbio/workshop/blob/master/data/parsed_crispr_group.txt

E execute o seguinte comando:

```
taxontree -treefile crispr_cas1b.tree -queryid "384117643|384117649"
-featuretable parsed_crispr_group.txt -delimiter "|" -position 0 -out
crispr
```

Esse comando irá incluir as informações sobre a classe do CAS que está presente no arquivo parsed_crispr_group.txt. Segue abaixo a árvore gerada.



Exercício

Submeta a árvore presente neste [link](#) no TaxOnTree. Para isso, utilize como query id: DEF1_HUMAN/1-52. Depois que a análise terminar, tente enraizar a árvore no local que você considera mais conveniente segundo as identificações taxonômica presente na árvore. Coloque a sua árvore no espaço abaixo.

Leitura complementar

Recomendo a leitura das seguintes referências para complementar os estudos sobre o assunto:

- Sakamoto, T., Ortega, J. M., TaxOnTree: a tool that generates trees annotated with taxonomic information, bioRxiv 2020.12.24.424364; doi: <https://doi.org/10.1101/2020.12.24.424364>
- Manual do TaxOnTree: <https://github.com/tetsufmbio/taxontree/blob/master/docs/manual.md>
- Sakamoto, T., Ortega, J.M. Taxallnomy: an extension of NCBI Taxonomy that produces a hierarchically complete taxonomic tree. BMC Bioinformatics 22, 388 (2021). <https://doi.org/10.1186/s12859-021-04304-3>
- Lopes, K.d.P., Campos-Laborie, F.J., Vialle, R.A. et al. Evolutionary hallmarks of the human proteome: chasing the age and coregulation of protein-coding genes. BMC Genomics 17, 725 (2016). <https://doi.org/10.1186/s12864-016-3062-y>